

## Inférence statistique devoir 2 (date limite : le jeudi 15 février)

Wen, Zehai ; Li, Qingyue

2024-02-13 17:45:50-05:00

## Exercice 1

Soit  $X_1, X_2, \dots, X_n$  un échantillon de taille  $n$  avec densité  $f_\theta(x) = \frac{1+\theta x}{2}\chi_{[-1,1]}(x)$ , où  $\theta \in [-1, 1]$  est inconnu. Écrire  $Y_i = \chi_{[0,1]}(X_i)$  pour tout  $i \in \{1, 2, \dots, n\}$ . Estimer  $\theta$  par la méthode des moments utilisant  $\{X_i\}_{i=1}^n$  et calculer l'écart quadratique moyenne. Proposez un autre estimateur de  $\theta$  qui améliore cet écart quadratique moyenne. Répétez les mêmes tâches utilisant  $\{Y_i\}_{i=1}^n$  et pas  $\{X_i\}_{i=1}^n$ .

**Solution** L'espérance de  $X_1$ ,  $E[X_1]$ , s'obtient en intégrant le produit de  $X_1$  par la densité de probabilité sur l'intervalle de définition de  $X_1$ , ce qui nous donne :

$$E[X_1] = \int_{-1}^1 x_1 \cdot \frac{1 + \theta x_1}{2} dx_1$$

Cette intégration aboutit à :

$$E[X_1] = \frac{\theta}{3}$$

$$E[X_1^2] = \frac{1}{3}$$

En utilisant la méthode des moments, on égalise le moment théorique, ici l'espérance calculée  $E[X_1]$ , avec le moment empirique, la moyenne d'échantillon  $\bar{X}$ , ce qui nous donne l'équation :

$$\bar{X} = \frac{\theta}{3}$$

En résolvant cette équation pour  $\theta$ , nous obtenons l'estimateur de  $\theta$  par la méthode des moments,  $\hat{\theta}_x$  :

$$\hat{\theta}_x = 3\bar{X}$$

$$\hat{\theta}_x = 3 \left( \frac{1}{n} \sum_{i=1}^n X_i \right)$$

L'écart quadratique moyen d'un estimateur  $\hat{\theta}_x$  est défini par :

$$EQM(\hat{\theta}_x) = E[(\hat{\theta}_x - \theta)^2] = E \left[ 9 \left( \frac{1}{n} \sum_{i=1}^n X_i \right)^2 - 6\theta \left( \frac{1}{n} \sum_{i=1}^n X_i \right) + \theta^2 \right]$$

On procède maintenant à la substitution de  $E[X_1]$  et  $E[X_1^2]$  dans notre expression précédente pour simplifier le calcul.

$$EQM(\hat{\theta}_x) = \frac{3 - \theta^2}{n}$$

La contribution attendue de  $X_1$  sous cette condition, ou l'espérance de  $Y_1$ , est calculée comme suit:

$$E[Y_1] = \int_0^1 \frac{1 + \theta x_1}{2} dx_1 = \frac{1}{2} + \frac{\theta}{4}$$

Comme  $Y_1$  est une fonction indicatrice dont les valeurs peuvent uniquement être 0 ou 1, la valeur de  $Y_1^2$  est en réalité identique à celle de  $Y_1$ . Cela est dû au fait que  $1^2 = 1$  et  $0^2 = 0$ . Par conséquent, nous avons  $E[Y_1^2] = E[Y_1]$ .

Par la méthode des moments, l'alignement de l'espérance théorique  $E[Y_1]$  avec la moyenne empirique des observations de  $Y_1$  donne :

$$E[Y_1] = \frac{1}{2} + \frac{\theta}{4} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Résoudre cette équation pour  $\theta$ , on introduit l'estimateur  $\hat{\theta}_y$ , qui est défini et obtenu par :

$$\hat{\theta}_y = 4 \left( \frac{1}{n} \sum_{i=1}^n Y_i \right) - 2,$$

offrant une estimation directe de  $\theta$  basée sur la moyenne d'échantillon des  $Y_i$ .

L'écart quadratique moyen d'un estimateur  $\hat{\theta}_y$  est défini par :

$$EQM(\hat{\theta}_y) = E[(\hat{\theta}_y - \theta)^2] = E \left[ 16 \left( \frac{1}{n} \sum_{i=1}^n Y_i \right)^2 - 8 \left( \frac{1}{n} \sum_{i=1}^n Y_i \right) (2 + \theta) + (2 + \theta)^2 \right]$$

On procède maintenant à la substitution de  $E[Y_1]$  et  $E[Y_1^2]$  dans notre expression précédente pour simplifier le calcul :

$$EQM(\hat{\theta}_y) = \frac{4 - \theta^2}{n}$$

Considérant l'estimateur  $\hat{\theta}_x = 3 \left( \frac{1}{n} \sum_{i=1}^n X_i \right)$ , avec  $X_i \in [-1, 1]$ , et  $\theta \in [-1, 1]$ , l'espace image de  $\hat{\theta}_x$  est  $[-3, 3]$ , couvre et dépasse l'intervalle de  $\theta$ . Cela indique que  $\hat{\theta}_x$  peut générer des estimations au-delà des valeurs réelles possibles de  $\theta$ .

Définissons la valeur ajustée  $\hat{\theta}_x^{adj}$  comme suit :

$$\hat{\theta}_x^{adj} = \hat{\theta}_x \cdot I(|\hat{\theta}_x| \leq 1) + 1 \cdot I(\hat{\theta}_x > 1) - 1 \cdot I(\hat{\theta}_x < -1)$$

On découvre que, grâce à l'ajustement post-traitement, l'erreur quadratique moyenne de l'estimateur ajusté est réduite par rapport à l'estimateur initial. Cela peut être exprimé mathématiquement comme suit :

$$E[(\hat{\theta}_x^{adj} - \theta)^2] \leq E[(\hat{\theta}_x - \theta)^2],$$

ce qui indique que cette méthode réussit à améliorer les écarts quadratiques moyens.

## Exercice 2

On a un échantillon de taille 2 de Cauchy( $\theta, 1$ ), où le centre  $\theta \in \mathbb{R}$  est inconnu. Estimer  $\theta$  selon la méthode du maximum de vraisemblance.

**Solution** La fonction de vraisemblance pour deux variables aléatoires indépendantes  $X_1, X_2$  est :

$$L(\theta|x_1, x_2) = f(x_1|\theta) \cdot f(x_2|\theta) = \left( \frac{1}{\pi} \frac{1}{1 + (x_1 - \theta)^2} \right) \left( \frac{1}{\pi} \frac{1}{1 + (x_2 - \theta)^2} \right)$$

Introduisons le nouveau paramètre  $\eta = \theta - \frac{x_1 + x_2}{2}$  et  $y = \frac{x_1}{2} - \frac{x_2}{2}$ , ce qui implique :

En remplaçant  $\theta$  par  $\eta$  dans la fonction de vraisemblance :

$$L(\eta) = \frac{1}{\pi^2} \cdot \frac{1}{1 + (y - \eta)^2} \cdot \frac{1}{1 + (y + \eta)^2} = \frac{1}{\pi^2 [( \eta^2 + 1 - y^2 )^2 + 4y^2]}$$

Trouver la valeur minimale de  $\eta^2 + 1 - y^2$  permet de déterminer la valeur maximale de  $L(\eta)$ . On conclut que lorsque  $\eta = \pm \sqrt{y^2 - 1}$ ,  $L(\theta)$  atteint sa valeur maximale. Donc on peut calculer l'estimateur de  $\theta$ ,  $\hat{\theta}$  :

$$\hat{\theta} = \pm \sqrt{\left[ \frac{(x_1 - x_2)^2 - 4}{4} \right]} + \frac{x_1 + x_2}{2}$$

### Exercice 3

Soit  $g : \mathbb{R} \rightarrow \mathbb{R}$  une fonction continue et décroissante. On suppose que toutes les fonctions  $f_\theta : \mathbb{R} \rightarrow \mathbb{R}$ , où  $\theta \in \mathbb{R}$ , définies par  $f_\theta(x) = g(|x - \theta|)$  sont densités de probabilité. Soit  $x_1, x_2, \dots, x_n$  un échantillon de taille  $n$  avec densité  $f_\theta$ , où  $\theta \in \mathbb{R}$  est inconnu. Écrire  $x_{(1)} \leq \dots \leq x_{(n)}$  pour les statistiques d'ordre. Montrez que l'estimateur de maximum de vraisemblance de  $\theta$  existe et se trouve dans l'intervalle  $[x_{(1)}, x_{(n)}]$ .

**Solution** L'estimateur du maximum de vraisemblance  $\theta_{\text{MLE}}$  est la valeur de  $\theta$  qui maximise la fonction de vraisemblance  $L(\theta) = \prod_{i=1}^n g(|x_i - \theta|)$ , avec  $g$  étant une fonction continue et décroissante. La propriété de décroissance de  $g$  entraîne que  $L(\theta)$  est maximisée lorsque  $\theta$  se situe au plus proche des  $x_i$ , et en considérant l'ensemble des observations dans l'intervalle compact  $[x_{(1)}, x_{(n)}]$ ,  $L(\theta)$  atteindra nécessairement son maximum dans cet intervalle d'après le théorème des valeurs extrêmes. Par conséquent,  $\theta_{\text{MLE}}$  doit exister à l'intérieur de  $[x_{(1)}, x_{(n)}]$ .